

# 基于博弈论的自监督学习策略分析：以 ADIOS 模型为例

李瑞杰

June 28, 2025

## Abstract

自监督学习 (SSL) 已成为计算机视觉领域获取有效表征的关键技术。在图像领域的自监督学习中，对比学习和掩码图像建模 (MIM) 是两大主流范式。本文聚焦于 MIM 领域的一项创新工作——ADIOS (Adversarial Inference-Occlusion Self-supervision) 框架，该框架通过引入对抗性机制来学习掩码函数和图像编码器。我们将运用博弈论的基本原理，特别是零和博弈和纳什均衡的概念，来深入剖析 ADIOS 中图像编码器与遮挡模型（掩码生成器）之间的动态交互过程。分析表明，这种对抗性设置可以被视为一个双人零和博弈，其目标是驱动图像编码器学习对语义信息更鲁棒的表征，同时促使遮挡模型生成更具挑战性且语义相关的掩码。本文旨在揭示博弈策略在提升自监督学习性能和表征质量方面的内在逻辑和潜力。

**关键词：**自监督学习；掩码图像建模；对抗学习；博弈论；零和博弈；纳什均衡

## 1 引言

在深度学习驱动的计算机视觉研究中，自监督学习通过代理任务从无标注数据中学习高质量图像表征，避免对大规模人工标注的依赖。我的研究聚焦于图像自监督学习，重点探讨对比学习和掩码图像建模 (MIM) 两类方法。对比学习通过吸引正样本对、排斥负样本对学习表征；MIM 借鉴 NLP 中 BERT 思想，通过预测或重建被遮挡图像部分进行学习。

MIM 方法（如 MAE、BEiT）常采用随机或固定掩码策略，但可能无法高效遮挡关键语义信息，限制模型深度语义推理能力。随机掩码易被局部像素相关性推断，类似 NLP 中仅掩盖字母而非词语。为此，Yuge Shi 等人提出 ADIOS 框架，引入可学习的遮挡模型，与图像编码器对抗训练。编码器最小化原始与掩码图像表征距离，遮挡模型则最大化此距离，生成语义丰富的掩码，促使编码器进行复杂语义推理。本文从博弈论视角深入分析 ADIOS 对抗学习机制，探讨其策略及对表征质量的提升作用。

## 2 ADIOS 模型核心机制

ADIOS 框架由两大核心组件构成：图像编码器 ( $E$ ) 和遮挡模型 ( $M$ )。

- **图像编码器 ( $E$ )**：其目标是学习对遮挡具有鲁棒性的图像表征。具体而言，它力求最小化原始图像  $x$  的表征  $E(x)$  与经遮挡模型生成的掩码  $m$  处理后的图像  $\hat{x}$  的表征  $E(\hat{x})$  之间的距离  $D(E(x), E(\hat{x}))$ 。

- **遮挡模型 ( $M$ ):**与编码器目标相反,它试图生成能最大化上述表征距离  $D(E(x), E(\hat{x}))$  的掩码  $m$ 。它旨在识别并遮挡对编码器最具挑战性的图像区域。

这两个模型通过一个 **min-max** 对抗性目标进行联合训练:  $\min_E \max_M D(E(x), E(\hat{x}))$ 。为防止遮挡模型生成无意义的极端掩码 (如全黑或全白), ADIOS 引入了稀疏性惩罚  $R(m)$ , 鼓励生成信息量更丰富的掩码。该框架的显著特点是通过对抗训练, 使遮挡模型  $M$  学习生成语义上更有意义的掩码, 这些掩码倾向于遮挡完整的物体或其关键部分, 从而迫使图像编码器  $E$  学习更高级别的语义理解和上下文推理能力。

### 3 ADIOS 模型的博弈论解读

ADIOS 框架中图像编码器  $E$  和遮挡模型  $M$  之间的对抗关系, 可以被清晰地建模为一个双人博弈过程。

#### 3.1 对抗训练的博弈框架

- **参与者 (Players):** 图像编码器 ( $E$ ) 作为博弈方 P1, 遮挡模型 ( $M$ ) 作为博弈方 P2。
- **策略空间 (Strategy Space):** P1 的策略是其所有可能的参数配置, 旨在最小化表征距离; P2 的策略也是其所有可能的参数配置, 旨在最大化该距离。
- **效用函数 (Utility Function):** 核心效用基于表征距离  $D(E(x), E(\hat{x}))$ 。P1 的目标是  $\min D$ , P2 的目标是  $\max(D - R(m))$  (考虑稀疏性惩罚)。
- **博弈类型:** 这是一个典型的双人零和博弈 (或常数和博弈), 因为一方的收益 (或损失的减小) 直接对应另一方的损失 (或收益的减小)。训练过程的迭代性也使其具有动态博弈的特征。

#### 3.2 编码器与遮挡模型的策略与效用分析

- **图像编码器 ( $E$ ) 的策略与目标:** 编码器的目标是学习强大的图像表征。在 ADIOS 的博弈中, 它必须面对一个“智能”对手。如果遮挡模型生成的掩码随机且不重要, 编码器可能通过学习局部特征“作弊”。然而, 由于遮挡模型会主动寻找最能混淆编码器的掩码, 编码器被迫学习更深层次的语义信息、物体部件关系及上下文依赖, 以使其表征在面对这些“恶意”掩码时仍保持一致性。其最优策略是发展出对这些精心设计的、最具挑战性遮挡的鲁棒性。
- **遮挡模型 ( $M$ ) 的策略与目标:** 遮挡模型的直接目标是最大化编码器原始表征与掩码后表征的差异。为此, 它必须“理解”图像中对编码器当前表征学习至关重要的部分。如果编码器依赖特定区域 (如鸟头), 遮挡模型的优选策略就是遮挡该区域。论文图 1 的 ADIOS 示例清晰展示了这一点: 生成的掩码倾向于覆盖语义实体。稀疏性惩罚  $R(m)$  对其策略起规范作用, 防止其采纳极端且无益于学习的掩码 (如全黑), 迫使其在“破坏性”和“信息量”间寻求平衡。

### 3.3 均衡与学习过程：走向纳什均衡

纳什均衡描述了一种状态没有参与者有动机单方面改变策略的状态。ADIOS 的 min-max 优化正是在寻找这样的均衡点。训练过程可视为编码器和遮挡模型间的持续“军备竞赛”：

1. 遮挡模型行动：在当前编码器状态下，生成最能迷惑编码器的掩码。
2. 编码器回应：面对“困难”掩码，调整参数，学习对这些遮挡更鲁棒的表征。
3. 随着编码器进步，旧的“困难”掩码可能失效，遮挡模型必须学习新的、更有效的掩码。

此迭代过程持续进行，双方不断适应对方。理论上，当系统达到纳什均衡时：

- **图像编码器 ( $E$ )**：已学习到对遮挡模型 ( $M$ ) 生成的最具挑战性掩码系列具有鲁棒性的表征。
- **遮挡模型 ( $M$ )**：已找到针对当前最优编码器  $E$  的最有效掩码生成策略。

这种均衡状态下学到的图像表征，因经历了最困难挑战，具有更强泛化能力和语义理解能力。

### 3.4 “语义化掩码”的博弈论意义

ADIOS 能生成语义上有意义的掩码，从博弈论角度看，这是遮挡模型追求其最大化效用目标时的必然结果。

- **为什么不是随机掩码？** 随机小块掩码易被编码器利用图像局部相关性恢复，表征距离小，对遮挡模型非最优。
- **为什么是语义掩码？** 为最大化表征距离，遮挡模型必须找到对编码器当前“理解”至关重要的区域，这些区域通常对应语义单元（如物体、物体显著部分）。遮挡这些区域迫使编码器利用更广阔上下文推理，而非仅依赖局部信息。例如，图 1 中对鸟的身体或背景特定区域的遮挡。因此，语义化掩码是遮挡模型在博弈中为最大化自身效用（即最大化对编码器的“破坏”）而演化出的智能策略，这反过来“训练”了编码器，使其具备更强语义推理能力。

## 4 博弈策略对模型性能的影响

ADIOS 论文中的实验结果为上述博弈论分析提供了有力支持。

- **分类和迁移学习性能提升**：ADIOS 在 ImageNet100、STL10 等数据集的分类任务及 CIFAR、Flowers102 等数据集的迁移学习中，均一致优于基线 SSL 方法（如 SimCLR, SimSiam, BYOL）。这表明通过对抗博弈达到的“均衡”状态下，图像编码器学习到的表征确实更鲁棒有效，它学习了更本质的视觉模式。
- **模型鲁棒性增强**：在背景挑战实验中，ADIOS 训练的模型对背景变化表现出更强鲁棒性。这可解释为，遮挡模型在博弈中可能学会识别并遮挡与前景相关的背景区域，或通过优先遮挡前景部分，间接迫使编码器减少对虚假相关背景信息的依赖。论文指出“ADIOS depends less on background information that are spuriously-correlated with object labels”，这正是博弈迫使编码器关注核心语义的结果。

- **学习到的掩码的有效性**：论文第 4.2 节 “Comparing Masking Schemes” 实验显示，使用 ADIOS 学习到的掩码进行训练，性能显著优于随机掩码方案，且接近甚至可比于使用真实物体分割掩码的方案。这说明，遮挡模型通过博弈学到的策略（如何生成掩码）确实比随机策略更优越，因为它为编码器量身定制了“课程难度”，使其学习效率更高。
- **轻量级 ADIOS (ADIOS-s) 的表现**：即使是计算成本较低的 ADIOS-s（每次随机采样一个生成的掩码训练），在 ImageNet100 上也取得了显著性能提升，尤其在 BYOL 上。这表明博弈的核心思想——即使是简化版的对抗——也能有效提升表征质量。

## 5 讨论与展望

将 ADIOS 框架理解为一个博弈过程，为我们提供了新的视角，但也引出了一些值得进一步探讨的问题：

- **博弈的复杂性与计算成本**：同时训练两个模型，特别是当遮挡模型生成多个掩码时，计算成本较高。ADIOS-s 是对此的缓解。未来可探索更高效的均衡求解算法或非对称博弈结构。
- **均衡的唯一性与稳定性**：在复杂深度学习模型中，min-max 优化可能存在多个局部纳什均衡。系统收敛点及其稳定性是值得研究的问题。
- **超越零和博弈**：虽然核心对抗机制是零和的，但整个系统最终目标（学习好表征）可视为双方的“间接合作”。未来或可引入合作博弈元素或多智能体博弈。
- **策略的可解释性**：ADIOS 生成的语义化掩码本身具可解释性，揭示模型认为重要的区域。分析遮挡模型策略演化过程，或有助于理解 SSL 模型如何建立对视觉世界的认知。

## 6 结论

通过运用博弈论视角，我们能深刻理解 ADIOS 框架中图像编码器与遮挡模型间的动态对抗关系。此过程可有效地建模为一个双人零和（或常数和）动态博弈。在此博弈中，图像编码器力求学习对最具挑战性遮挡鲁棒的表征，而遮挡模型则力求生成能最大化干扰编码器当前表征的、语义上最关键的掩码。这种对抗性 min-max 优化驱动系统向纳什均衡状态演化，其中编码器被迫学习更深层次语义信息和上下文推理能力，而遮挡模型则学会生成语义上有意义的“智能”掩码。

ADIOS 的成功实验结果，包括其在各类任务上的性能提升、鲁棒性增强以及学习到的掩码的有效性，均印证了这种博弈策略在自监督学习中的价值。博弈论不仅为分析现有 SSL 方法提供了有力理论工具，也为未来设计更智能、更高效的自监督学习算法开辟了新思路。通过精心设计的博弈机制，我们可以引导模型在“挑战”与“适应”的循环中不断进化，从而从未标记数据中发掘出更丰富、更本质的知识。